

用户行为数据分析背景大纲

一、项目背景

在电商行业精细化运营的发展趋势下，海量用户行为数据是挖掘用户偏好、优化商品运营、提升转化效率的核心资产，数据驱动决策已成为电商平台提升业务效率、强化用户体验的核心竞争力。

淘宝作为国内头部电商平台，拥有亿级用户与商品规模，用户从浏览、收藏、加购到购买的全链路行为数据中，蕴含着用户消费决策规律、商品价值潜力与平台转化瓶颈。本次实习项目以淘宝用户行为数据为载体，以“业务问题牵引+全流程实战”为核心模式，带领大家完整走完从数据处理、特征挖掘、模型搭建到业务落地的数据分析全链路，在实战中掌握数据分析师的核心工作方法与工程化能力。

本次项目将围绕五大核心业务问题展开实践：

- 如何高效处理大规模用户行为数据，保障数据质量与处理效率？
- 如何搭建多维度特征体系，为用户行为预测提供高质量输入？
- 如何通过机器学习模型精准预测用户购买行为，支撑精准运营？
- 如何利用深度学习捕捉用户行为序列规律，进一步提升预测效果？
- 如何将数据分析与建模结果转化为可落地的业务策略，创造实际业务价值？

二、项目核心目标

（一）业务目标

基于淘宝用户全链路行为数据，完成用户购买行为预测建模，输出用户分群、转化漏斗、商品价值等维度的深度洞察，提出可落地的用户运营与商品优化建议，模拟实现数据对业务的正向赋能。

（二）能力培养目标

通过全流程项目实战，全面提升实习生在电商数据分析领域的核心能力：

- 掌握大规模数据的工程化处理方法，具备数据清洗、质量管控与性能优化能力
- 建立体系化的特征工程思维，能够从业务视角构建高区分度的特征
- 掌握传统机器学习与深度学习建模的全流程方法，具备模型调优与效果评估能力
- 培养业务导向的数据分析思维，能够从数据中提炼可落地的业务决策建议
- 建立工程化与规范化的项目管理意识，掌握代码版本管理与成果沉淀方法

三、数据集说明

3.1 数据来源与规模

本项目采用淘宝用户行为数据集，覆盖约100万独立用户、400万件商品的全链路交互行为，完整记录用户在平台内的浏览、收藏、加购、购买四类核心行为，具备典型的电商用户行为代表性。

3.2 数据集字段说明

字段名	数据类型	取值范围	详细说明
user_id	string	约100万种	用户唯一标识，用于区分不同用户
item_id	string	约400万种	商品唯一标识，用于区分不同商品
category_id	string	约1万种	商品类目唯一标识，用于划分商品所属品类
behavior_type	string	1/2/3/4	用户对商品的行为类型：1=浏览(pv)、2=收藏(fav)、3=加购物车(cart)、4=购买(buy)
timestamp	string	-	行为发生的时间戳，格式为 YYYY-MM-DD HH，精确到小时

四、项目整体阶段规划

项目全程分为四个阶段，循序渐进推进，每个阶段均设置明确的任务与交付要求：

- 第一阶段：数据工程体系搭建与理论储备** 完成大数据分析环境搭建、领域知识储备、数据清洗与预处理，搭建规范化的项目工程框架，解决大规模数据的读取与质量管控问题。
- 第二阶段：深度特征工程与探索性分析** 搭建数据库完成基础SQL分析，从用户、商品、时间等多维度构建特征体系，通过探索性数据分析挖掘用户行为规律与转化特征，输出核心业务洞察。
- 第三阶段：多模型建模与性能优化** 完成样本构建与数据集划分，依次实现传统机器学习模型与深度学习模型的训练调优，开展模型融合与可解释性分析，并设计业务落地方案。
- 第四阶段：成果沉淀与项目复盘** 完成代码工程化封装、项目总报告与汇报材料撰写，进行全流程项目复盘，沉淀可复用的分析方法与工具。

五、项目全流程执行链路

本项目遵循「数据驱动、链路闭环」的原则，按照**原始数据→数据治理→特征工程→模型构建→部署评估→业务落地**的正向数据流依次推进，各环节前后依赖、逐层输出，具体执行顺序与核心动作如下：

步骤1：原始数据接入与标准化预处理

前置输入：原始淘宝用户行为数据集 **核心动作：**

- 完成数据集合规性校验，采用分块读取+并行处理方案加载亿级数据，解决单节点内存瓶颈
- 执行多维度数据清洗：基于业务规则与IQR/ 3σ 统计法则处理异常值，按 用户-商品-行为-时间 四元组去重，统一时间格式并校验时间有效性
- 完成数据类型压缩与非必要字段筛选，转换为Parquet格式存储，提升后续读写效率 **产出物：**清洗后的标准化基础数据集、数据质量校验报告

步骤2：多维度中间表构建与设计

前置输入：标准化基础数据集 **核心动作：**

- 按照第三范式设计三类核心中间表，实现数据预聚合与维度解耦：
 - 用户维度中间表：**聚合单用户的全量行为统计、活跃度、转化能力等基础指标
 - 商品维度中间表：**聚合单品/类目下的流量、转化、复购等商品价值指标
 - 时间维度中间表：**按小时/日/周维度聚合平台整体的行为趋势、时段分布等指标
- 为中间表设置统一关联键（user_id、item_id、category_id）并建立索引，支撑后续快速查询与特征拼接 **产出物：**用户、商品、时间三类聚合中间表、中间表设计说明文档

步骤3：特征挖掘与特征宽表拼接

前置输入：三类维度中间表 + 原始明细行为数据 **核心动作：**

- 基于中间表扩展基础统计特征，同时深度挖掘三类高阶特征：
 - 生命周期特征：用户连续活跃天数、商品热度衰减系数、行为序列间隔与时序跳转特征
 - 隐式语义特征：通过SVD矩阵分解提取用户-商品交互隐向量，计算商品共现相似度与关联规则特征
 - 业务导向特征：RFM用户价值分、全链路各环节转化率、用户偏好强度得分
- 以「用户-商品对」为主键，关联所有维度的特征字段，拼接形成统一的**特征宽表**，实现一行样本对应完整特征集合 **产出物：**全量特征宽表、特征字典文档

步骤4：核心特征筛选与特征预处理

前置输入：全量特征宽表 **核心动作：**

- 完成特征预处理：数值型特征做标准化/归一化，高维类别特征采用目标编码替代独热编码，稀疏特征做预嵌入处理
- 通过方差阈值法、相关性分析、互信息法三重筛选，剔除冗余特征、低区分度特征与高共线性特征
- 验证特征与目标变量的相关性，输出特征重要性预评估结果，确定最终入模特征集 **产出物**：筛选后的核心特征数据集、特征有效性评估报告

步骤5：样本构建与特征数据集划分

前置输入：核心特征数据集 **核心动作**：

- 明确定义目标变量：用户-商品对在未来7天内是否产生购买行为，以此构建二分类正负样本
- 采用分层抽样策略，按7:2:1比例划分训练集、验证集、测试集，保证三类数据集的样本分布一致性
- 对比SMOTE过采样、欠采样、类别权重调整三种方案，处理购买样本占比低的类别不平衡问题 **产出物**：划分完成的训练/验证/测试集、样本构建说明文档

步骤6：模型选型与基线训练

前置输入：训练集与验证集 **核心动作**：

- 选定两类模型体系，分别覆盖可解释性基线与性能上限需求：
 1. **传统机器学习模型**：逻辑回归（可解释性基准）、XGBoost、LightGBM（树模型性能基准）
 2. **深度学习序列模型**：LSTM/GRU（基础序列基准）、DIN深度兴趣网络（电商场景专用模型）
- 完成各模型的初始化与基线版本训练，输出初始性能指标，建立效果对比基准 **产出物**：各模型基线版本、基线性能对比表

步骤7：模型训练调优与融合

前置输入：模型基线版本、验证集 **核心动作**：

- 传统模型：通过Optuna自动超参数调优框架，优化树深度、学习率、叶子节点数等核心参数
- 深度学习模型：调整嵌入维度、隐藏层结构、Dropout比例，引入多头注意力机制，搭配学习率衰减与早停策略防止过拟合
- 设计Stacking融合方案，融合多模型预测结果，进一步提升整体预测性能 **产出物**：调优后的最优单模型、融合模型、性能对比报告

步骤8：模型推理与本地部署封装

前置输入：最优模型文件、特征预处理逻辑 **核心动作**：

- 将数据预处理、特征计算、模型预测全链路封装为可调用的推理脚本

- 实现本地批量推理能力，支持输入原始行为数据、自动输出用户购买概率预测结果
- 编写推理接口使用说明，保障预测流程可复用、可复现 **产出物**：本地推理工具包、推理接口API文档

步骤9：模型效果综合评估

前置输入：测试集、模型预测结果 **核心动作**：

- 以AUC为核心指标，搭配准确率、召回率、F1分数等多维度指标，在测试集上评估模型泛化能力
- 开展模型可解释性分析：基于特征系数解释逻辑回归，基于SHAP值解释树模型与深度学习模型，识别影响购买决策的核心特征
- 分析预测错误样本的特征，总结模型在冷启动用户、长尾商品场景下的局限性 **产出物**：模型性能评估报告、可解释性分析报告、错误样本分析总结